

摘 要

本文以客户是否认购银行产品为目标变量，对 22500 条营销记录开展客户分层。数据无 NaN 缺失，排除标识字段 id 后无重复样本，认购率为 13.12%。实验按目标变量进行 8:2 分层抽样；仅在训练集上对连续特征等频分 5 箱，对分类特征保持原类别且不合并，不要求 WOE 单调，并以 $IV > 0.02$ 保留 17 个特征。随后采用 One-Hot 编码和类别权重建立逻辑回归与随机森林。逻辑回归 Recall 为 0.7237；随机森林 Precision、F1、最大 KS 和第一十分位 Lift 分别为 0.4994、0.5806、0.6665 和 4.5254，前 10% 客户认购率为 59.33%。结果表明，随机森林具有更好的名单排序与营销分层能力。

关键词：银行电话营销；WOE；IV；逻辑回归；随机森林；Lift；KS

ABSTRACT

This study segments 22,500 bank-marketing records using product subscription as the target. The data contain no NaN values or duplicated observations after excluding the identifier. An 8:2 stratified split is used. On the training set, continuous variables are divided into five quantile bins, categorical variables retain their original groups without merging, and WOE monotonicity is not imposed. With the rule $IV > 0.02$, 17 features are retained. Logistic regression and random forest models use one-hot encoding and class weighting. Logistic regression obtains a recall of 0.7237. Random forest achieves a precision of 0.4994, an F1-score of 0.5806, a maximum KS statistic of 0.6665, and a top-decile lift of 4.5254. Its highest-ranked decile has a subscription rate of 59.33%, supporting probability-ranked customer targeting.

KEY WORDS: bank telemarketing; WOE; information value; logistic regression; random forest; lift; KS statistic

目 录

摘要	I
ABSTRACT	I
一、 绪论	1
(一) 研究背景	1
(二) 研究任务与实验设定	1
(三) 技术路线	1
二、 数据理解与预处理	2
(一) 数据集结构与变量体系	2
(二) 数据质量与目标变量分布	2
(三) 数值变量与 unknown 类别	4
(四) 分层抽样与实验划分	5
(五) 信息泄露控制	5
三、 特征分箱与 IV 信息价值筛选	6
(一) WOE 与 IV 原理	6
(二) 分箱与平滑机制	6
(三) IV 排序与筛选结果	6
(四) 筛选结果解释	8
四、 模型构建与评价方法	8
(一) 采用 One-Hot 编码的原因	8
(二) 逻辑回归模型	9
(三) 随机森林模型	9
(四) 样本不均衡与类别权重	9
(五) 模型设置与评价指标	10
五、 实验结果与比较分析	11
(一) 分类效果比较	11
(二) 十分位 Lift 分析	12
(三) KS 曲线分析	13
(四) 综合评价	14
(五) 稳健性与部署补充	14
六、 精准营销应用与模型治理	15
(一) 客户分层与触达策略	15
(二) 阈值与成本收益	16
(三) 部署边界与监测	16
七、 结论与展望	17
(一) 主要结论	17
(二) 局限性与改进方向	17
参考文献	18

附录 1 数据字段说明	19
附录 2 程序运行与输出文件	19

插图目录

1 目标变量 <code>subscribe</code> 的类别分布	3
2 全量特征 IV 值及筛选阈值	8
3 两类模型十分位 Lift 对比	13
4 逻辑回归标准 KS 曲线	13
5 随机森林标准 KS 曲线	14

表格目录

1 候选特征的业务分类	2
2 数据质量概况	3
3 主要数值特征描述性统计	4
4 分类变量中的 <code>unknown</code> 情况	5
5 分层抽样后的类别分布	5
6 全量特征 IV 值降序排序	7
7 <code>contact</code> 变量的 One-Hot 编码示例	9
8 训练集类别权重	10
9 模型与预处理设置	10
10 测试集分类评价指标	11
11 测试集混淆矩阵统计	12
12 两类模型第 1 至第 10 十分位 Lift	12
13 KS 指标比较	13
14 5 个分层随机种子下的测试指标范围	15
15 不含 <code>duration</code> 的部署补充模型	15
16 基于预测十分位的客户运营建议	16
17 原始数据字段及业务含义	19
18 主要程序输出文件	20

一、绪论

（一）研究背景

电话营销是银行推广定期存款、理财产品及其他金融服务的重要渠道。人工外呼能够提供更充分的产品解释和互动，但同时具有显著的人力成本和客户打扰成本。若营销对象缺乏筛选，大量电话会落在低意向客户上，使坐席资源、活动预算和客户关系受到损耗。已有研究表明，基于历史客户属性、联系行为和宏观环境建立预测模型，可以改善银行电话营销的目标客户选择 [1]。

数据挖掘在该场景中的价值主要体现为三个层面：第一，通过特征分析识别与认购行为关联较强的变量；第二，通过监督学习模型为每名客户生成认购意向分数；第三，通过 Lift、KS 等排序指标判断高分客户是否真正集中在名单前部。与单纯追求整体准确率相比，这种分析框架更贴近精准营销的实际目标 [2]。

（二）研究任务与实验设定

研究以 `subscribe=yes` 为正类、`subscribe=no` 为负类，`id` 仅作记录标识并在建模前删除。实验条件固定为：测试集占 20%，按目标类别分层抽样，随机种子设为 42；连续特征等频分为 5 箱，分类特征保持原始类别且不合并，不要求 WOE 单调；以 $IV = 0.02$ 为筛选临界点；通过类别权重处理样本不均衡。分箱边界、WOE、IV 和特征筛选均只根据训练集确定，测试集只用于最终评价。

在上述设定下，研究完成两个相互衔接的任务：

1. 对全部连续特征进行等频 5 分箱，对分类特征按原始类别直接分组，计算 WOE 和 IV，并以 $IV = 0.02$ 为临界点标注保留特征和待剔除特征；
2. 基于筛选后的有效特征建立逻辑回归和随机森林模型，在测试集上输出 Precision、Recall 和 F1-Score；将预测正概率从高到低划分为 10 个等份，计算第 1 至第 10 十分位 Lift；分别绘制标准 KS 曲线并比较区分能力。

（三）技术路线

本文遵循“数据理解—实验划分—特征筛选—模型训练—排序评价—业务解释”的技术路线。为避免测试集标签参与特征筛选，先划分训练集和测试集，再仅使用训练集计算分箱边界与 IV。模型阶段保留原始数值信息，并对类别变量实施 One-Hot 编码，使 IV 仅承担筛选职责，而不将 WOE 直接解释为预测概率。

二、数据理解与预处理

（一）数据集结构与变量体系

原始数据共有 22500 条客户记录和 22 个字段。样本编号字段为 id，目标变量为 subscribe，其余 20 个字段为候选特征。根据业务含义，可将特征划分为客户属性、信贷属性、营销接触信息和宏观经济指标四类，如表1所示。

表 1 候选特征的业务分类

变量类别	代表字段	主要含义
客户属性	age、job、marital、education	描述客户人口统计与社会属性
信贷属性	default、housing、loan	描述违约、住房贷款和消费贷款状况
营销接触	contact、month、duration、campaign、pdays 等	描述联系渠道、时点、强度和历史反馈
宏观经济	emp_var_rate、cons_conf_index、lending_rate3m 等	描述营销发生时的外部经济环境

目标变量 subscribe 取值为 yes 或 no。本文将 yes 映射为正样本 1，表示客户认购；将 no 映射为负样本 0，表示未认购。id 仅用于区分记录，不具有稳定业务含义，因此在建模前删除。

（二）数据质量与目标变量分布

数据质量检查结果见表2。排除唯一编号 id 后，数据不存在 NaN 缺失和完全重复样本；分类变量中的 unknown 仍需要作为信息状态处理，数值变量存在长尾，目标变量比例明显失衡。

表 2 数据质量概况

检查项目	结果	处理结论
样本规模	22500 条	满足本次建模与独立测试需要
字段数量	22 个	包含 20 个候选特征、1 个标签和 1 个编号
NaN 缺失值	0 个	无需进行均值、中位数或众数填补
重复样本（不含 id）	0 条	无需去重
标签有效性	yes/no 两类	映射为 1/0




图 1 目标变量 subscribe 的类别分布

未认购客户共有 19548 人，占 86.88%；认购客户共有 2952 人，占 13.12%。为准确说明类别不均衡对评价的影响，首先定义准确率：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

其中， TP 和 TN 分别为正确预测的认购与未认购样本数， FP 和 FN 分别为误判为认购和漏判的认购样本数。

若采用一个不具备识别能力的多数类基准模型，将所有客户均预测为“未认购”，则有 $TN = 19548$ 、 $FN = 2952$ 、 $TP = FP = 0$ ，其准确率为

$$\frac{19548}{22500} = 86.88\%. \quad (2)$$

然而，该模型的认购类 Recall 和 F1-Score 均为 0，一个潜在认购客户也无法识别。因此，86.88% 是**多数类基准准确率**，并不代表模型具有营销价值。在类别不均衡条件下，单独使用准确率会高估模型的正类识别能力，本文将 Precision、Recall、F1、Lift 和 KS 作为主要评价指标。

（三）数值变量与 unknown 类别

表3给出主要数值特征的描述性统计。duration、campaign 和 pdays 的均值与中位数差异明显，表现出偏态或大量集中取值。连续变量统一采用等频分箱，极端值在 IV 计算中会被转化为有序区间；模型阶段则分别通过标准化和树模型结构降低尺度与分布差异的影响。本文不在缺乏业务证据的情况下直接删除极端观测。

表 3 主要数值特征描述性统计

特征	最小值	最大值	均值	中位数	标准差
age	16.00	101.00	40.41	38.00	12.09
duration	0.00	5149.00	1146.30	353.00	1432.43
campaign	0.00	57.00	3.36	1.00	7.22
pdays	0.00	1048.00	773.99	964.00	326.93
previous	0.00	6.00	1.32	0.00	1.92
emp_var_rate	-3.40	1.40	0.08	1.10	1.57
cons_price_index	87.64	99.46	93.55	93.54	2.81
cons_conf_index	-53.28	-25.55	-39.88	-40.60	5.81
lending_rate3m	0.60	5.27	3.30	3.92	1.61
nr_employed	4715.42	5489.50	5137.21	5133.95	170.67

unknown 是数据中已经编码的类别，而不是文件层面的空值。default 的 unknown 占比达到 21.60%，直接删除会损失大量样本并可能引入选择偏差。分类特征保持原始类别且不进行合并，因此 unknown 作为独立类别参与 IV 统计和

One-Hot 编码。

表 4 分类变量中的 unknown 情况

特征	类别数	unknown 数量	unknown 占比
job	12	274	1.22%
marital	4	320	1.42%
education	8	994	4.42%
default	3	4860	21.60%
housing	3	886	3.94%
loan	3	889	3.95%

（四）分层抽样与实验划分

数据划分使用 `train_test_split` 完成。测试集比例设为 20%，按目标变量 `subscribe` 分层，随机种子固定为 42。具体过程是先把认购客户和未认购客户分别视为两个子总体，再在每个类别内部随机抽取约 20% 进入测试集，其余约 80% 进入训练集，最后合并两类样本形成完整数据集。

表 5 分层抽样后的类别分布

数据集	样本数	未认购数	认购数	认购率
原始总体	22500	19548	2952	13.1200%
训练集	18000	15638	2362	13.1222%
测试集	4500	3910	590	13.1111%

原始总体认购率为 13.1200%，训练集和测试集认购率分别为 13.1222% 和 13.1111%，三者基本一致。分层抽样使类别比例近似一致；受样本数必须为整数的约束，比例仍有轻微差异。例如 $2952 \times 20\% = 590.4$ ，测试集实际分配 590 个认购样本。固定随机种子 42 使该划分可复现。

（五）信息泄露控制

本文先完成训练集与测试集划分，再仅利用训练集标签计算 WOE、IV 和筛选结果，测试集始终用于最终评价。另需注意，`duration` 是电话结束后才能完整获得的通话时长。包含全部候选字段的主实验保留该变量，以完整比较原始字段的统计预测能力；面向拨打前名单筛选时，则删除 `duration` 并重新训练。

三、特征分箱与 IV 信息价值筛选

（一）WOE 与 IV 原理

WOE（Weight of Evidence，证据权重）和 IV（Information Value，信息价值）广泛用于金融评分中的变量分析 [3]。对某特征第 i 个分箱，记 p_i^+ 和 p_i^- 分别为该箱正样本和负样本占全部正、负样本的比例，则

$$\text{WOE}_i = \ln \left(\frac{p_i^+}{p_i^-} \right), \quad (3)$$

$$\text{IV} = \sum_i (p_i^+ - p_i^-) \text{WOE}_i. \quad (4)$$

IV 越大，说明正负客户在该特征不同取值或区间中的分布差异越明显。IV 衡量的是单变量区分能力，不等同于因果效应，也不能保证变量在多变量模型中仍具有同等贡献。

（二）分箱与平滑机制

连续特征原则上采用等频 5 分箱，即按照训练集样本分位数将观测尽可能平均地划入 5 个区间。当特征存在大量重复值时，多个分位点可能重合，程序通过 `duplicates="drop"` 删除重复边界，因此有效箱数可能少于 5。分类特征不进行人工合并，直接以原始类别作为分箱。

为避免某一箱内正样本或负样本计数为 0 导致 $\ln(0)$ ，各箱正负计数均加入 0.5 的平滑项。实验不施加 WOE 单调约束，因此不为形成单调趋势而二次合并分箱。该处理保持了流程的客观性和可复现性，但可能牺牲部分稳定性和解释性。

（三）IV 排序与筛选结果

表6列出训练集上全部候选特征的 IV 值。按照 $IV > 0.02$ 保留、 $IV \leq 0.02$ 剔除的规则，共保留 17 个特征。

表 6 全量特征 IV 值降序排序

排名	特征	IV 值	有效箱数	筛选结果
1	month	0.5434	10	保留
2	emp_var_rate	0.4584	4	保留
3	duration	0.3928	5	保留
4	lending_rate3m	0.2625	5	保留
5	job	0.1971	12	保留
6	default	0.1611	3	保留
7	age	0.1441	5	保留
8	marital	0.1306	4	保留
9	contact	0.1304	2	保留
10	cons_conf_index	0.0819	5	保留
11	education	0.0744	8	保留
12	loan	0.0655	3	保留
13	poutcome	0.0636	3	保留
14	nr_employed	0.0583	5	保留
15	pdays	0.0517	5	保留
16	campaign	0.0383	5	保留
17	housing	0.0361	3	保留
18	previous	0.0179	3	待剔除
19	day_of_week	0.0090	5	待剔除
20	cons_price_index	0.0029	5	待剔除




图 2 全量特征 IV 值及筛选阈值

保留特征为 month、emp_var_rate、duration、lending_rate3m、job、default、age、marital、contact、cons_conf_index、education、loan、poutcome、nr_employed、pdays、campaign 和 housing。待剔除特征为 previous、day_of_week 和 cons_price_index。

（四）筛选结果解释

month 的 IV 为 0.5434，在所有特征中最高，说明不同联系月份的认购率差异明显。这可能反映活动安排、季节性资金需求或宏观环境差异，也提示模型可能对具体营销周期形成依赖。duration 的 IV 为 0.3928，具有较强区分能力，但其业务含义具有双重性：更长通话可能意味着客户兴趣更高，也可能是营销人员已成功吸引客户后的结果。因此，在拨打前模型中应将其移除。

四、模型构建与评价方法

（一）采用 One-Hot 编码的原因

数据中 job、marital、education、contact、month 和 poutcome 等变量是无序类别变量。逻辑回归和 scikit-learn 的随机森林不能直接接收字符串，因此需要数值化。若简单将职业编码为 1、2、3，模型会错误地引入“3 大于 2 大于 1”以及类别间距离关系，而职业、婚姻状况等并不具有这种自然顺序。

One-Hot 编码将每个类别转换为相互独立的 0/1 指示变量。以 contact 为例：

表 7 contact 变量的 One-Hot 编码示例

原始类别	contact_cellular	contact_telephone
cellular	1	0
telephone	0	1

该处理不人为赋予类别顺序，适合逻辑回归解释不同类别的相对影响。随机森林虽然对数值缩放不敏感，但若使用整数标签，树会用诸如 “ $\text{job_code} \leq 2.5$ ” 的阈值切分类别，同样形成虚假顺序，因此本文对两个模型统一使用 One-Hot 编码。编码器设置 `handle_unknown="ignore"`，若测试集中出现训练阶段未见的新类别，程序不会报错，而是将该类别对应的指示变量设为 0。

（二）逻辑回归模型

逻辑回归是金融分类任务中常用的可解释基准模型 [4]。对客户特征向量 x ，模型先计算线性得分，再利用 Sigmoid 函数映射为正类分数：

$$z = \beta_0 + \sum_{j=1}^p \beta_j x_j, \quad P(y = 1 | x) = \frac{1}{1 + \exp(-z)}. \quad (5)$$

本实验对类别变量进行 One-Hot 编码，对数值变量进行标准化，设置最大迭代次数为 2000，并采用 `class_weight="balanced"`。

（三）随机森林模型

随机森林通过对 Bootstrap 样本训练多棵决策树并集成各树结果，以降低单棵树的方差 [5]。本文设置 500 棵树、最大深度 16、叶节点最少样本数 3，并采用 `balanced_subsample` 类别权重方式。随机森林能够刻画非线性关系和变量交互，对特征尺度不敏感，但其加权输出更适合作为排序分数，不应未经校准就解释为真实购买概率。

（四）样本不均衡与类别权重

本文不通过复制少数类或删除多数类改变样本数量，而是通过类别权重改变不同类别对损失函数或节点划分的影响。逻辑回归将 `class_weight` 设为 `balanced`，`scikit-learn` 按以下公式计算第 j 类权重：

$$w_j = \frac{N}{Kn_j}, \quad (6)$$

其中 N 为训练集样本总数， K 为类别数， n_j 为训练集中第 j 类样本数。训练集共有 $N = 18000$ 条样本，未认购样本 $n_0 = 15638$ ，认购样本 $n_1 = 2362$ ，因此

$$w_0 = \frac{18000}{2 \times 15638} = 0.5755, \tag{7}$$

$$w_1 = \frac{18000}{2 \times 2362} = 3.8103, \tag{8}$$

$$\frac{w_1}{w_0} = 6.6207. \tag{9}$$

表 8 训练集类别权重

类别	样本数	balanced 权重	相对未认购类倍数
未认购 (0)	15638	0.5755	1.0000
认购 (1)	2362	3.8103	6.6207

因此，逻辑回归训练时一个认购样本对目标函数的相对影响约为一个未认购样本的 6.62 倍。这并不等同于把认购样本复制 6.62 次，也没有改变训练集中的真实样本数量。

随机森林的 `balanced_subsample` 不使用一组完全固定的权重，而是在每棵树的 Bootstrap 子样本上按式(6)重新计算。由于各树抽到的正负样本数略有不同，具体权重会围绕 0.5755 和 3.8103 小幅波动，总体相对倍数接近 6.62。类别权重会影响节点划分时的加权不纯度以及叶节点类别统计。

（五）模型设置与评价指标

模型设置见表9。

表 9 模型与预处理设置

模型	特征处理	类别不均衡	主要参数
逻辑回归	数值标准化；类别 One-Hot	balanced；固定权重	max_iter=2000
随机森林	数值原尺度；类别 One-Hot	balanced_subsample；逐树重算	n_estimators=500 max_depth=16 min_samples_leaf=3

在默认阈值 0.5 下，计算

$$\text{Precision} = \frac{TP}{TP + FP}, \quad (10)$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (11)$$

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (12)$$

第 d 个十分位 Lift 定义为该分箱实际认购率与测试集总体认购率之比：

$$\text{Lift}_d = \frac{r_d}{r_{\text{all}}}, \quad d = 1, \dots, 10. \quad (13)$$

标准 KS 曲线按预测正概率降序排列样本，分别计算累计正样本比例和累计负样本比例：

$$\text{KS} = \max_t |\text{TPR}(t) - \text{FPR}(t)|. \quad (14)$$

KS 和 Lift 均利用概率排序，比单一阈值下的分类结果更贴近营销名单分层需求 [6]。模型使用 scikit-learn 实现 [7]。

五、实验结果与比较分析

（一）分类效果比较

表10列出测试集上的主要指标。Accuracy 作为补充结果列出，但不作为核心决策依据。

表 10 测试集分类评价指标

模型	Accuracy	Precision	Recall	F1-Score
多数类基准	0.8688	0.0000	0.0000	0.0000
逻辑回归	0.7931	0.3573	0.7237	0.4784
随机森林	0.8687	0.4994	0.6932	0.5806

多数类基准虽然 Accuracy 达到 0.8688，但完全不能识别认购客户。逻辑回归和随机森林的主要价值体现在正类识别与排序能力，而不是简单提高总体 Accuracy。逻辑回归在 590 名实际认购客户中识别出 427 名，Recall 为 0.7237；随机森林识别出 409 名，Recall 为 0.6932。随机森林只少覆盖 18 名认购客户，但

假正例由逻辑回归的 768 人降低到 410 人，减少 358 人，Precision 因而提高至 0.4994。

表 11 测试集混淆矩阵统计

模型	TN	FP	FN	TP	预测认购人数
逻辑回归	3142	768	163	427	1195
随机森林	3500	410	181	409	819

随机森林 F1 为 0.5806，高于逻辑回归的 0.4784，说明其在潜在客户覆盖和推荐纯度之间达到更好的综合平衡。在坐席容量有限的条件下，减少大量低意向客户的无效联系通常具有更高运营价值；若活动目标是尽量不遗漏潜在认购者，逻辑回归较高的 Recall 仍具有意义。

（二）十分位 Lift 分析

表 12 两类模型第 1 至第 10 十分位 Lift

十分位	逻辑回归 Lift	随机森林 Lift
1	3.8475	4.5254
2	2.7119	2.9492
3	0.8814	1.1695
4	0.4407	0.4237
5	0.5424	0.1864
6	0.4068	0.5085
7	0.3729	0.1695
8	0.2881	0.0678
9	0.2712	0.0000
10	0.2373	0.0000

每个十分位包含 450 名测试客户。第 1 十分位中，逻辑回归和随机森林分别包含 227 名和 267 名认购者，对应认购率为 50.44% 和 59.33%。若随机抽取 450 名客户，按照测试集总体认购率预计仅约 59 人认购；随机森林高分名单的认购密度约为随机营销的 4.53 倍。




图3 两类模型十分位 Lift 对比

(三) KS 曲线分析

表 13 KS 指标比较

模型	最大 KS	对应累计样本比例	对应概率阈值
逻辑回归	0.5336	20.76%	0.5711
随机森林	0.6665	26.67%	0.3723




图4 逻辑回归标准 KS 曲线




图 5 随机森林标准 KS 曲线

逻辑回归最大 KS 为 0.5336，随机森林最大 KS 为 0.6665。随机森林的累计正样本曲线在名单前部上升更快，而累计负样本曲线上上升较慢，因此高意向与低意向客户的分离程度更高。最大 KS 对应阈值可作为运营阈值讨论的参考，但不应机械使用；最终阈值应结合电话成本、产品收益、坐席容量和客户打扰成本共同确定。

（四）综合评价

综合来看，随机森林在 Precision、F1、Lift 和 KS 上均优于逻辑回归，更适合本数据下以有限资源优先触达高意向客户的目标。逻辑回归的优势主要体现在 Recall 和模型结构解释性，可作为业务基准和模型监控参照。

（五）稳健性与部署补充

为检验单次划分是否偶然，在随机种子 7、21、42、84 和 123 下重复“分层划分—训练集 IV 筛选—模型训练—测试集评价”全流程。表14给出 5 次结果范围。随机森林最大 KS 始终位于 0.6474 至 0.6665，第一十分位 Lift 位于 4.0000 至 4.5254，均高于逻辑回归，说明模型优劣关系具有稳定性。主实验采用的随机种子 42 对应结果处于区间较高端，因此不将其解释为跨样本的精确总体水平。特征 previous 在 1 次划分中略高于 0.02，其余 4 次低于阈值，属于临界特征。

表 14 5 个分层随机种子下的测试指标范围

模型	Precision	Recall	F1	最大 KS	第一十分位 Lift
逻辑回归	0.3294–0.3573	0.6746–0.7237	0.4486–0.4784	0.4855–0.5336	3.5763–3.8475
随机森林	0.4678–0.4994	0.6712–0.7000	0.5530–0.5806	0.6474–0.6665	4.0000–4.5254

表10至表13展示包含全部原始候选字段的主实验，其中 duration 用于衡量原始字段集合能够达到的统计预测能力。若业务确认该变量在拨打前不可获得，则使用不含 duration 的部署补充模型，结果见表15。删除该字段后，随机森林最大 KS 为 0.5640，第一十分位 Lift 仍为 4.1017，说明前置名单筛选仍有较强区分力，但低于包含全部字段的主实验。

表 15 不含 duration 的部署补充模型

模型	Precision	Recall	F1	AUC	最大 KS	第一十分位 Lift
逻辑回归	0.3668	0.7237	0.4869	0.8076	0.5392	3.9153
随机森林	0.4889	0.6339	0.5520	0.8182	0.5640	4.1017

随机森林训练集与测试集 AUC 分别为 0.9834 和 0.8922，最大 KS 分别为 0.8559 和 0.6665，显示一定拟合差距。结合多随机种子结果，测试集排序能力总体稳定，但正式部署仍应采用时间外验证并限制模型复杂度。

六、精准营销应用与模型治理

（一）客户分层与触达策略

包含全部候选字段的主模型用于展示特征筛选与模型比较结果；实际拨打前名单应使用当时可获得字段训练的补充模型。银行可以按照相应模型的预测分数从高到低将客户划分为十分位，并据此安排触达资源。

表 16 基于预测十分位的客户运营建议

客户层级	预测范围	建议触达方式	运营目标
重点层	第 1 十分位	优先人工外呼，配置经验坐席并及时跟进	提高单位外呼转化率
次重点层	第 2-3 十分位	常规外呼与数字渠道组合	兼顾覆盖率与成本
观察层	第 4-6 十分位	短信、App 消息或低成本批量触达	保留潜在机会并控制成本
低优先级层	第 7-10 十分位	原则上不进行高频人工外呼	减少无效联系和客户打扰

（二）阈值与成本收益

分类阈值不应只根据 0.5 或最大 KS 点确定。设每次电话成本为 C ，成功认购带来的期望净收益为 R ，模型在某阈值下的 TP 和 FP 分别为正确与错误触达数量，则简化营销净收益为

$$\Pi = R \times TP - C \times (TP + FP). \quad (15)$$

当业务更重视客户覆盖时，可适当降低阈值；当坐席紧张或电话成本较高时，应提高阈值或直接采用前 $K\%$ 名单。

（三）部署边界与监测

若模型用于电话拨打前生成名单，必须根据业务时点确认 duration 是否已经可得；不可得时应采用表15所示的补充模型，并确保其他特征也能在拨打前获得。正式上线后应监测特征分布漂移、总体认购率、前十分位 Lift、KS、Recall 以及不同客户群体中的误报率。当指标持续下降或营销策略发生变化时，应重新分箱、重新计算 IV 并训练模型。类别加权后的输出更适合作为排序分数；若业务需要真实概率，应在独立验证集上进行概率校准。

七、结论与展望

（一）主要结论

本文完成了银行产品认购数据的质量检查、分层抽样、连续变量等频分箱、分类变量原类别分组、WOE-IV 计算、特征筛选、逻辑回归与随机森林建模，以及 Precision、Recall、F1、10 个十分位 Lift 和 KS 评价。数据无 NaN 缺失，排除 id 后无重复样本，但认购客户仅占 13.12%。分层抽样后，训练集和测试集认购率分别为 13.1222% 和 13.1111%，与总体 13.1200% 基本一致。

20 个候选特征中有 17 个满足 $IV > 0.02$ 。模型结果显示，逻辑回归 Recall 较高，而随机森林在 Precision、F1、最大 KS 和第一十分位 Lift 上均更优。随机森林最高 10% 客户的认购率达到 59.33%，为总体认购率的约 4.53 倍，因此被选为主实验的推荐模型。5 个分层随机种子下，该模型最大 KS 均不低于 0.6474；不含 duration 的部署补充模型第一十分位 Lift 仍达到 4.1017。

（二）局限性与改进方向

本研究仍存在以下局限：一是拨打前不可获得 duration 时只能采用补充模型；二是多随机种子检查不能替代跨时间验证，且随机森林存在拟合差距；三是模型尚未系统搜索超参数和校准概率；四是 IV 不能完整反映多变量交互与因果机制。后续应以滚动时间窗检验稳定性，并把电话成本、预期收益与客户打扰纳入决策函数 [8]。

参考文献

- [1] MORO S, CORTEZ P, RITA P. A data-driven approach to predict the success of bank telemarketing[J]. Decision Support Systems, 2014, 62: 22–31.
- [2] PROVOST F, FAWCETT T. Data Science for Business[M]. Sebastopol: O'Reilly Media, 2013.
- [3] SIDDIQI N. Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards[M]. 2nd ed. Hoboken: Wiley, 2017.
- [4] HOSMER D W, LEMESHOW S, STURDIVANT R X. Applied Logistic Regression[M]. 3rd ed. Hoboken: Wiley, 2013.
- [5] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45(1): 5–32.
- [6] FAWCETT T. An introduction to ROC analysis[J]. Pattern Recognition Letters, 2006, 27(8): 861–874.
- [7] PEDREGOSA F, VAROQUAUX G, GRAMFORT A, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825–2830.
- [8] KUHN M, JOHNSON K. Applied Predictive Modeling[M]. New York: Springer, 2013.

附录 1 数据字段说明

表 17 原始数据字段及业务含义

字段	业务含义	变量类别
id	样本编号	标识变量
age	客户年龄	客户属性
job	客户职业类别	客户属性
marital	婚姻状况	客户属性
education	最高教育水平	客户属性
loan	是否持有个人消费贷款	信贷属性
default	信用卡是否违约	信贷属性
housing	是否持有住房贷款	信贷属性
contact	上一次联系渠道	营销接触
month	上一次联系月份	营销接触
day_of_week	上一次联系星期	营销接触
duration	上一次联系时长（秒）	营销接触
campaign	本次活动期间联系次数	营销接触
pdays	距上一次联系的间隔天数	营销接触
previous	本次活动前联系次数	营销接触
poutcome	此前营销活动结果	营销接触
emp_var_rate	就业变动率（季度）	宏观经济
cons_price_index	消费者价格指数（月度）	宏观经济
cons_conf_index	消费者信心指数（月度）	宏观经济
lending_rate3m	3 个月同业拆借利率（日度）	宏观经济
nr_employed	雇员人数（季度）	宏观经济
subscribe	客户是否认购产品（yes/no）	目标变量

附录 2 程序运行与输出文件

配套程序为 bank_marketing_analysis.py。将程序与 data.csv 放在同一目录，执行：

```
python bank_marketing_analysis.py
```

程序自动生成 bank_marketing_outputs 文件夹，主要输出见表18。

表 18 主要程序输出文件

文件	内容
data_summary.csv	数据规模、缺失、重复、认购率和多数类基准准确率
split_summary.csv	原始总体、训练集和测试集的正负样本数量及认购率
class_weight_summary.csv	balanced 类别权重及认购类相对倍数
numeric_summary.csv	数值特征描述性统计
unknown_summary.csv	分类变量 unknown 数量与占比
iv_ranking.csv	全部特征 IV 排序和筛选状态
iv_detail_*.csv	各特征分箱、WOE 和 IV 分量
model_evaluation.csv	主实验模型的 Accuracy、Precision、Recall、F1、AUC、KS 和 Lift
lift_deciles_*.csv	两模型十分位认购率与 Lift
ks_curve_*.csv	两模型 KS 曲线数据
deployment_no_duration_*.csv	不含 duration 的部署补充模型评价、Lift 和 KS
stability_runs.csv	5 个分层随机种子的逐次测试结果
stability_summary.csv	多随机种子指标均值、标准差和范围
feature_selection_stability.csv	各特征跨随机种子的 IV 与入选稳定性
fig_*.png	目标分布、IV、Lift 和 KS 图形