

公共数据开放与企业诉求的因果效应及传导机制研究 ——基于政府留言板的 LLM 识别与双重机器学习分析

摘要

公共数据开放是数字政府建设和数据要素市场化配置的重要内容，也是提升政府治理透明度、优化营商环境和畅通政企沟通渠道的重要抓手。企业诉求表达作为市场主体参与公共治理、反馈经营困难和获取政策支持的重要方式，能够反映地区制度环境与政企互动水平。

本文基于 2011—2023 年中国城市层面面板数据和人民网“地方领导留言板”文本数据展开研究。首先，利用爬虫技术获取超过 300 万条留言文本，并结合关键词粗筛与大语言模型精筛，构建“两阶段语义识别框架”，从中识别出 5.77 万条民营企业诉求文本，进一步汇总形成城市一年份层面的企业诉求指标。其次，将公共数据开放平台上线视为准自然实验，采用双重机器学习方法识别其平均处理效应，并通过平行趋势检验、安慰剂检验等多种稳健性检验证明因果识别的可靠性。最后，构建营商环境指标，检验其中介传导机制。

研究结果表明：第一，公共数据开放显著提升企业诉求表达活跃度，说明数据开放能够降低政企信息不对称，增强企业对正式沟通渠道的使用意愿。第二，事件研究法和平行趋势检验支持准自然实验设定，安慰剂检验表明基准结果并非由随机政策时点驱动；在调整样本、剔除异常值、更换机器学习模型、改变交叉折数和替换被解释变量后，结论依然稳健。第三，公共数据开放的作用存在区域异质性，在东北和中部地区效应更强，西部地区次之，东部地区边际效应相对较弱。机制分析进一步表明，公共数据开放能够通过优化地区营商环境，增强企业政策获取能力和政企互动意愿，进而促进企业诉求表达。

本文的边际贡献在于：一是基于大规模政府留言板文本和大语言模型识别企业诉求，拓展了企业诉求测度方法；二是采用双重机器学习、事件研究法和安慰剂检验相结合的识别策略，提高了因果推断的稳健性；三是从营商环境视角揭示公共数据开放影响企业诉求表达的传导机制。研究结论为推进公共数据高质量开放、完善企业诉求回应机制和优化地区营商环境提供了经验证据与政策启示。

关键词：公共数据开放；企业诉求；大语言模型；双重机器学习；营商环境

目录

摘要	II
一、 绪论	1
(一) 研究背景与意义	1
(二) 研究创新点	1
(三) 研究思路	2
二、 文献综述	3
(一) 公共数据开放相关研究	3
(二) 企业诉求相关研究	3
(三) 双重机器学习相关研究	3
(四) 国内外相关研究述评	4
三、 理论分析和模型假设	4
四、 指标设计和模型构建	5
(一) 数据来源	5
(二) 基于 LLM 的企业诉求识别	5
(三) LLM 识别结果的人工验证	7
(四) 指标选择	7
1. 被解释变量：企业诉求量	7
2. 解释变量：公共数据开放	8
3. 控制变量	8
(五) 描述性统计	10
(六) 模型构建	11
五、 实证分析	13
(一) 基准回归分析	13
(二) 因果识别检验	13
1. 事件研究法与平行趋势检验	13
2. 安慰剂检验	14
(三) 稳健性检验	15

1. 调整研究样本	15
2. 剔除异常值影响	15
3. 考虑省份—时间交互固定效应	15
4. 更换机器学习模型	15
5. 更换交叉折数	16
6. 替换被解释变量	17
(四) 异质性检验	17
1. 东北地区：产业结构偏重与信息摩擦较高	18
2. 中部地区：产业承接与转型带来的需求释放	18
3. 西部地区：基础约束下的吸收能力限制	18
4. 东部地区：信息环境完善与边际效应递减	18
六、 机制分析	18
(一) 公共数据开放对营商环境的驱动逻辑	18
1. 金融服务环境维度	18
2. 人力要素环境维度	19
3. 市场环境维度	19
4. 社会服务环境维度	19
5. 创新环境维度	19
(二) 营商环境指标构建	19
(三) 基于 DML 的中介效应检验模型	20
七、 研究结论和展望	22
(一) 结论	22
(二) 建议	23
八、 参考文献	24
九、 附录	28
十、 致谢	30

表格与插图清单

图 1 研究思路图 2

表 1 系统提示词 6

表 2 人工验证结果混淆矩阵（单位：条） 7

表 3 主要变量定义 9

表 4 变量的描述性统计分析 10

表 5 基准回归结果 13

图 2 平行趋势检验 13

图 3 安慰剂检验：随机置换政策时点的伪效应分布 14

表 6 更换机器学习模型的结果 16

表 7 替代被解释变量检验结果 17

表 8 异质性分析结果 17

表 9 营商环境指标构建 20

表 10 公共数据开放对企业诉求表达及营商环境影响的回归结果 22

公共数据开放与企业诉求的因果效应及传导机制研究 ——基于政府留言板的 LLM 识别与双重机器学习分析

一、绪论

（一）研究背景与意义

公共数据作为国家重要的基础性战略资源，其在赋能经济社会高质量发展中的作用日益凸显。近年来，我国公共数据资源开发利用制度规则逐步建立，数据产品和服务不断丰富，已发布四批次共一百个公共数据“跑起来”示范场景，数据要素在赋能实体经济、扩大消费需求、拓展投资空间、提升治理能力中的要素作用充分发挥。与此同时，企业作为国民经济的细胞，是市场经济的主要参与者，解决企业的问题需要多听企业的声音，了解企业面临的问题和真正需求，才能抓住要害、对症下药。因此，如何有效释放公共数据开放对企业诉求响应的助推作用，成为政府和社会各界广泛讨论的行动议题。

那么，公共数据平台开放是否驱动了企业诉求的变化？如果该效应得到证实，其背后的作用机制是什么？公共数据开放对企业诉求的影响在不同地区、不同企业特征下又具有何种差异？对于这些问题，尽管政策层面已明确要求“制定涉企法规规章和规范性文件必须听取相关企业和行业协会商会意见”，并且公共数据资源开发利用已进入规范化、规模化阶段，但准确评估公共数据开放对企业诉求影响的实证研究仍较为缺乏。现有的相关文献多集中于数字经济对高质量发展的宏观效应（如创业活跃度、全要素生产率等），或从理论层面阐述公共数据赋能经济社会发展的路径，较少有研究在统一框架下定量考察公共数据平台开放与企业诉求之间的因果关系及其作用机制。对此，本文选取营商环境作为中介视角展开研究，尝试基于一个完整的框架探讨公共数据开放如何影响企业诉求。并且，本文选取城市层面作为区域对象，能够在更加细致的空间尺度上对公共数据开放、政府回应与企业诉求进行研究。

（二）研究创新点

本研究的创新与贡献主要体现于三方面。第一，在研究对象上，基于“地方领导留言板”大规模真实文本构建城市层面的企业诉求表达指标，为观察政企互动提供了微观证据。第二，在变量构建上，引入大语言模型识别企业诉求，并通

过人工验证提高文本分类结果的可信度。第三，在识别方法上，将公共数据开放平台上线视为准自然实验，采用双重机器学习处理高维控制变量和潜在非线性关系，提高因果识别的稳健性。^{[32][37]}。

（三）研究思路




图 1 研究思路图

二、文献综述

（一）公共数据开放相关研究

公共数据开放是数字政府建设和数据要素市场化的重要内容。现有研究认为，政府数据开放能够通过提高信息透明度、降低交易成本和优化资源配置，促进治理能力提升与经济高质量发展。郑石明^[1]指出数据开放有助于环境治理创新；蔡菲莹和黄秀霁^[2]、黄先海和虞柳明^[3]、章昌平等^[4]从企业创新、城市创新和区域创新能力等角度验证了政府数据开放的积极效应。张莉等、赵涛发现公共数据开放能够推动数字经济和高质量发展^{[5][6]}；彭远怀、吴武清等表明政府数据开放可通过优化营商环境、降低信息处理成本提升企业生产率。^{[7][9]}总体，既有文献已揭示公共数据开放的经济与治理效应，但对其如何影响企业诉求表达仍关注不足。

（二）企业诉求相关研究

国内外关于企业诉求的相关研究历经理论深化与方法革新，逐步形成了多维度分析框架。早期研究基于 Pfeffer 和 Salancik 的资源依赖理论与 North 的制度理论，主要聚焦单一维度的问题，如融资约束和市场准入壁垒^{[34][35][36][11]}。随着世界银行营商环境指标的引入，学者们构建了中国化评价体系，揭示了要素获取等核心诉求，并开始关注经济周期的动态影响^{[12][13][14]}。研究方法从利用 CPES 数据库的传统问卷调查向大数据与 AI 技术跨越，卢圣华等人（2023）运用 ChatGLM 实现诉求分类，准确率达 98.7%，推动了理论研究与政策实践的深度耦合。^[15]

（三）双重机器学习相关研究

双重机器学习在政策实证研究中的应用日益广泛，其核心优势在于通过结合 Neyman 正交化与交叉拟合，有效缓解了高维控制变量和复杂模型设定所带来的正则化偏误与过拟合偏误，从而为低维政策参数的因果推断提供了稳健基础。在具体实证中，DML 已被用于评估人工智能、数字普惠金融等多种政策变量的处理效应。多项研究共同表明，DML 凭借其处理高维数据、自动筛选控制变量及弱化模型设定的灵活性，已成为政策评估中识别因果机制、检验稳健性与探索异质性的工具，尤其在传统参数方法难以应对的复杂数据下展现出显著优势^{[17][18][19]}。

（四）国内外相关研究述评

对国内外研究现状的梳理后，发现政府开放数据与企业行为这一研究主题虽然有了一定的研究基础和理论成果，但仍存在显著缺口：一是宏观视角主导，缺乏对企业诉求文本的细粒度分析；二是对中国地方政府数据开放试点的差异化路径关注不足；三是数据开放的微观效应尚未充分验证。^{[19][20]}

三、理论分析和模型假设

企业诉求表达是市场主体与政府部门之间信息传递、问题反馈和政策互动的重要形式，其活跃程度不仅反映企业经营过程中面临的现实需求，也体现了政企沟通渠道的可及性与有效性。公共数据开放通过释放政府掌握的政策、审批、监管、公共服务和市场运行等信息，能够显著提高政府信息透明度，降低企业搜寻政策信息、审批流程、融资支持、用工服务和公共资源配置等方面信息的成本。在信息更加充分和公开的条件下，企业能够更及时地识别自身权益、政策机会与制度约束，进而形成更明确的问题反馈和诉求表达。同时，公共数据开放也提升了政府治理的数字化、透明化和规范化水平，有助于增强企业对正式政企沟通渠道的信任。当企业认为其诉求更可能被政府部门看见、回应和解决时，便更有动力通过领导留言板等公开平台表达经营困难、政策需求和发展建议。因此，公共数据开放并不必然表现为企业诉求数量的减少，反而可能通过降低信息不对称、提升渠道信任和强化企业参与治理意愿，推动企业诉求表达更加活跃。基于此，本文提出如下假设：

H1：公共数据开放能够提升企业诉求表达活跃度。

在公共数据开放直接提升企业诉求表达活跃度的基础上，营商环境还可能构成其发挥作用的重要中介机制。公共数据开放有助于推动政务服务流程透明化、公共资源配置精准化和市场规则公开化，提升企业对地区制度环境、服务效率和政府回应能力的整体感知。当营商环境改善后，企业不仅更容易获取经营相关信息，也更容易形成对正式政企沟通渠道的信任，认为自身诉求更可能被识别、回应和解决，从而提高表达经营困难、政策需求和服务反馈的积极性。基于此，本文提出如下假设：

H2：公共数据开放能够通过优化地区营商环境提升企业诉求表达活跃度。

四、指标设计和模型构建

（一）数据来源

数据来源于以下几个方面：首先，城市数据来源于 2008~2023 年《中国城市统计年鉴》的面板数据，在剔除严重缺失值与无法识别的样本之后，进一步采用插值法对缺失值进行补充。另外，相关变量数据主要来源于国泰安数据库、复旦大学联合国家信息中心数字中国研究院发布的《中国地方政府据开放报告》。

“地方领导留言板”的网友留言记录来源为全国性网络问政平台人民网。自 2006 年试运行以来，该平台便广受地方政府及公众关注。据人民网统计，已有 26 个省份建立回复留言的固定工作机制，各级党政机关及领导人在平台公开回复网民。平台由人民网牵头，有效避免地方政府控制舆论的可能，大大减少了选择性呈现网民意见和投诉的现象，从而保证了数据的客观性。此外，留言的目的性和匿名性有助于真实反映留言者的诉求。我们通过爬虫搜集了 2011—2023 年人民网“地方领导留言板”平台上的所有留言和回复记录，共计 3084861 条。

（二）基于 LLM 的企业诉求识别

本文以人民网“地方领导留言板”中的非结构化留言文本为基础，借助大语言模型识别民营企业诉求。相较于传统关键词或规则匹配方法，大语言模型具有更强的语义理解和信息抽取能力，能够在复杂语境下判断留言是否属于企业主体围绕生产经营困难、政策需求或制度约束提出的真实诉求。本文采用 LLM-as-a-Judge 范式，将企业诉求识别转化为二分类语义判别任务，即在给定提示词约束和留言文本输入的条件下，由模型输出“YES”或“NO”，其中“YES”表示该文本属于企业诉求，“NO”表示非企业诉求。

在具体实现上，本文采用通义千问大语言模型（Qwen3.6-Plus）开展文本识别，并构建“两阶段语义识别”框架。第一阶段为关键词粗筛。本文构建涵盖企业主体、经营要素、政务服务、财税政策和市场环境等维度的关键词词典，对原始留言文本进行初步筛选，尽可能保留与企业生产经营相关的候选样本，以提高潜在企业诉求的召回率。第二阶段为模型精筛。在候选样本基础上，本文通过 System Prompt 向模型明确企业诉求的判定标准：一是留言主体应为民营企业、个体工商户等市场经营主体，并具有第一人称表达特征；二是留言内容应围绕融

资约束、用工问题、审批效率、政策咨询、市场环境等经营相关问题；三是留言应具有明确诉求导向，而非单纯事实描述；四是排除消费者投诉、环境举报、一般民生问题及无实质诉求文本。

从形式上看，该识别过程可表述为 LLM-as-a-Judge 函数：模型在给定系统提示词 C 和输入文本 x 的条件下，通过概率生成机制输出二分类结果 $\varepsilon \in \{0,1\}$ 。其中， $\varepsilon = 1$ 表示文本被识别为企业诉求， $\varepsilon = 0$ 表示非企业诉求。为避免模型自由生成带来的格式噪声，本文在提示词中要求模型不得输出解释性文本，并在程序端对异常输出进行标准化校验。

$$\varepsilon_i = f_{LLM}(x_i, C), \varepsilon_i \in \{0,1\} \quad (1)$$

为提升识别结果稳定性，模型调用过程中设置温度参数 **temperature** 为 0，以减少随机性并提高判别一致性。基于上述方法，本文最终从原始留言中识别出 57,705 条民营企业诉求文本，并据此构建城市一年份层面的企业诉求量指标，用以刻画不同地区企业诉求表达活跃度。

表 1 系统提示词

结构	系统提示词
任务	判断文本是否属于民营企业等市场经营主体以第一人称主动表达的真实诉求，并输出二分类结果（YES/NO）。
解释	（1）主体要求：文本须由企业经营主体（如民营企业、个体工商户等）以第一人称表达； （2）内容要求：须围绕企业生产经营中的具体困难、问题或政策诉求，包括融资约束、用工问题、审批效率、市场环境及政策建议等； （3）表达要求：需具有明确诉求导向，而非单纯描述或信息陈述； （4）排除规则：剔除消费者投诉、环境举报、一般民生问题、无主体表述及无实质诉求文本。
准则	基于 LLM-as-a-Judge 范式，在给定提示词约束下，对文本语义进行整体理解，并将其映射至“是否构成企业真实经营约束与制度性诉求”的判别空间；判别过程综合考虑主体身份、语义指向与问题性质，实现对非结构化文本的经济含义识别。
格式	输出结果严格限定为“YES”或“NO”，不包含任何解释性文本或附加内容；模型调用设置 temperature=0 ，以降低随机性并提高判别一致性。

（三）LLM 识别结果的人工验证

为检验 LLM 识别结果的可靠性，本文进一步设置人工验证与稳健性检验环节。从模型判定为企业诉求（YES）和非企业诉求（NO）的文本中进行分层随机抽样，分别抽取 200 条，共形成 400 条人工验证样本。人工标注者在不知道模型判定结果的情况下，仅依据留言文本独立判断其是否属于企业诉求。人工标注环节由两名标注者独立判断是否属于企业诉求；若两名标注者结论不一致，则引入第三名标注者复核，并以多数投票结果作为最终人工标签。

人工复核结果显示，200 条模型判定为 YES 的样本中有 196 条被人工确认为企业诉求，200 条模型判定为 NO 的样本中有 189 条被人工确认为非企业诉求。

表 2 人工验证结果混淆矩阵（单位：条）

真正例（TP）	假正例（FP）	真负例（TN）	假负例（FN）
196	4	189	11

由此计算得到，准确率为 $(196 + 189)/400 = 96.25\%$ ，精确率为 $196/(196 + 4) = 98.00\%$ ，召回率为 $196/(196 + 11) = 94.69\%$ ，F1 值为 96.32%。上述结果表明，LLM 识别结果整体准确性较高，尤其在判定为企业诉求的样本中具有较高精确率；少量误差主要来自企业主体表达不显性或文本同时包含个人与经营性诉求的边界样本。

（四）指标选择

1. 被解释变量：企业诉求量

语义识别后，将识别结果以城市-年份为基本分析单元，统计每一地市在每一年度内被识别为“民营企业诉求”的留言数量，构建城市层面的企业诉求量。考虑到不同城市间留言总量及规模差异较大，本文对诉求数量进行对数化处理，以缓解数据分布的右偏性并降低极端值对估计结果的影响。

该变量从企业实际表达行为出发，刻画了企业在特定制度与营商环境下对政府提出问题反映、政策诉求及协调需求的总体强度，能够较为直接地反映企业在经营过程中所面临的约束程度与制度摩擦。与传统基于宏观统计数据或问卷调查构建的指标相比，企业诉求变量具有更强的现实针对性与动态性，能够捕捉微观主体在不同阶段的真实关切。

2. 解释变量：公共数据开放

公共数据开放的政策处理变量（*post*）表示城市 *i* 在第 *t* 年及以后是否上线公共数据开放平台。参考复旦大学数字与移动治理实验室发布的《2023 中国地方公共数据开放报告（城市）》，整理出各城市是否上线公共数据开放平台的基础数据，并且将其与华中师范大学信息管理学院发布的《中国政府开放数据利用研究报告（2022）》进一步对照。同时，借鉴复旦大学数字与移动治理实验室发布的《2023 中国地方公共数据开放报告（城市）》的方法，通过以下两步进一步进行检验：首先，将各地区公共数据开放平台域名限定于 *gov.cn*，将其作为确认官方公共数据开放平台的依据，且必须由地级市以上行政级别的政府部门负责建设与运营，同时通过开设专门且统一平台或者由政府部门在官网设置专栏的形式开放；其次，通过在搜索引擎中对各地区名称加关键词（“数据开放”“数据资源”“公共资源”等）加以验证。据此，最后获得了截至 2023 年 204 个城市（含有直辖市、副省级城市与地级市）的公共数据平台上线时间，将上线公共数据平台的城市设定为 *treat*，将首次上线时间以及之后年份设定为 *post*，进而构建城市—年份层面城市是否上线公共数据开放平台的虚拟变量。

3. 控制变量

城市层面控制变量包括：①经济发展水平。经济发展水平与生产要素集聚密切相关，进而影响企业经营环境及诉求表达行为，本文采用人口密度衡量城市要素集聚程度，并同时纳入地区生产总值刻画城市整体经济规模。②产业结构升级。产业结构反映资源配置方式与经济发展阶段，服务业占比越高，越有利于企业获取专业化服务支持，本文采用第三产业增加值占 GDP 比重衡量产业结构。③人力资本水平。人力资本是影响信息获取与技术应用的重要因素，进而影响企业对公共数据的利用能力，本文采用普通高等学校在校学生数与户籍人口之比衡量。④公共服务水平。公共服务水平影响企业经营环境及城市吸引力，本文采用每百人公共图书馆藏书量衡量。⑤传统基础设施。交通运输与物流条件能够降低交易成本、提升企业运行效率，本文采用公路货运量的自然对数（加 1 处理）衡量传统基础设施水平。⑥互联网发展水平。互联网基础设施有助于降低信息不对称并提高数据获取效率，本文采用电信业务收入的自然对数（加 1 处理）衡量。⑦金

融发展水平。金融资源可得性影响企业融资约束及经营决策，本文采用年末金融机构各项贷款余额与地区生产总值之比衡量。⑧财政压力水平。财政压力反映地方政府收支约束状况，并可能影响公共资源配置及政策实施效果，本文采用地方财政一般预算内支出与收入之比衡量。⑨科学支出水平。科学支出体现政府对创新环境的支持力度，进而影响企业发展与信息利用能力，本文采用科学支出的自然对数（加 1 处理）衡量。⑩对外开放水平。对外开放有助于引入外部资本与技术，影响企业行为模式，本文采用外商投资企业数量的自然对数衡量。⑪城市发展水平。城市发展阶段会系统性影响企业活动，本文采用人均地区生产总值的自然对数衡量。⑫城市治理水平。良好的城市治理有助于改善营商环境，本文采用生活垃圾无害化处理率衡量。⑬交通便捷程度。交通条件影响要素流动与企业区位选择，本文采用高速公路里程与户籍人口之比衡量。[20][21][24]

表 3 主要变量定义

变量名称	变量符号	变量定义与说明
经济规模	GDP	地区生产总值（万元）
要素集聚水平	DENSITY	人口密度（人/平方公里）
产业结构	INDUS	第三产业增加值占 GDP 比重（%）
人力资本水平	HC	普通高等学校在校学生数/户籍人口
公共服务水平	PUBLIC	每百人公共图书馆藏书量
传统基础设施	INFRA	ln(公路货运量+1)
互联网发展水平	INTERNET	ln(电信业务收入+1)
金融发展水平	FINANCE	年末金融机构贷款余额/地区生产总值
财政压力水平	FISCAL	地方财政一般预算内支出/地方财政一般预算内收入
科学支出水平	SCIENCE	ln(科学支出+1)
城市发展水平	PGDP	ln(人均地区生产总值)
对外开放水平	FDI	ln(外商投资企业数)
城市治理水平	ENV	生活垃圾无害化处理率（%）
交通便捷程度	ROAD	高速公路里程/户籍人口

（五）描述性统计

表 4 报告了主要变量的描述性统计结果。总体来看，各城市在经济规模、要素集聚、人力资本、公共服务、金融发展和交通便捷程度等方面存在明显差异，说明样本具有较强的区域异质性。其中，经济规模、公共服务水平和人力资本水平的标准差较大，反映出不同城市发展基础和公共资源配置能力差异显著；金融发展、财政压力和科学支出等变量也呈现一定离散性，表明地方资源禀赋和政策供给能力并不均衡。上述特征说明，在评估公共数据开放对企业诉求表达的影响时，有必要控制城市经济、产业、财政、基础设施和治理能力等因素。本文在双重机器学习框架下主要采用随机森林、XGBoost、LightGBM 和 GBDT 等树模型作为辅助学习器，由于树模型主要依据变量排序和节点划分进行拟合，对变量量纲差异相对不敏感，因此未对所有变量进行统一归一化处理；同时，对分布偏态较强的变量已进行对数化处理，以降低极端值对估计结果的影响。

表 4 变量的描述性统计分析

	均值	标准差	中位数	最小值	最大值
经济规模	25587013.02	38863211.43	13534133	618352	472190000
要素集聚水平	432.8533	333.4546	358	5	2648
产业结构	41.6472	10.2888	41.03	8.58	84.85
人力资本水平	193.4676	246.2288	102.8996	0.5758	1870.7475
公共服务水平	60.3381	106.9306	33	2	4325
传统基础设施	8.913	0.9178	8.9468	3.0445	12.586
互联网发展水平	12.4453	1.0142	12.3816	3.1781	16.452
金融发展水平	1.0218	0.6648	0.8337	0.0753	12.8171
财政压力水平	2.9535	1.9514	2.3832	0.6488	18.025
科学支出水平	10.2394	1.5129	10.0838	6.1527	15.5293
城市发展水平	10.6214	0.6846	10.6497	8.1309	12.4863
对外开放水平	2.9819	1.6867	2.7081	0	8.4707
城市治理水平	90.5868	18.1291	99.99	0.44	100.6
交通便捷程度	1.3899	1.3058	1.1017	0.0914	36.5575

（六）模型构建

本文将各城市公共数据开放平台上线时间与个体差异视为一项准自然实验，采用双重机器学习（Double Machine Learning, DML）方法估计公共数据开放对企业诉求表达活跃度的因果影响。DML 的基本思想是在高维控制变量条件下，先利用机器学习方法分别刻画控制变量对结果变量和处理变量的影响，再通过正交化处理识别核心处理效应。该方法与 Frisch-Waugh-Lovell 定理所体现的“净化”思想一致，即在剔除控制变量影响后，利用处理变量与结果变量的剩余变动估计因果效应。具体模型设定如下：[24][25]

结果方程：

$$Y = \theta D + g(X) + \varepsilon, \quad E(\varepsilon|D, X) = 0 \quad (2)$$

处理方程：

$$D = m(X) + \eta, \quad E(\eta|X) = 0 \quad (3)$$

其中， Y 为结果变量； D 为处理变量，表示城市是否开通公共数据开放平台（开通记为 1，未开通记为 0）； X 为高维控制变量集，涵盖城市经济特征、社会特征、政策环境等多维因素； θ 为待估计参数，即公共数据开放对企业诉求表达的平均因果处理效应（Average Treatment Effect, ATE）； $g(X)$ 与 $m(X)$ 为未知函数，分别刻画控制变量对结果变量与处理变量的影响，允许非线性、非参数形式，需借助机器学习方法进行估计； ε 与 η 为误差项，满足条件均值独立假设。

本文 DML 的估计过程主要包括三个步骤：第一，将样本划分为若干子样本，并在训练样本中分别估计 $g(X)$ 与 $m(X)$ ；第二，在留出样本中构造残差项 $Y_i - \hat{g}(X_i)$ 和 $D_i - \hat{m}(X_i)$ ；第三，基于残差化后的变量估计处理效应 θ 。通过交叉拟合，可以避免同一样本同时用于机器学习拟合与参数估计，从而降低过拟合对因果参数估计的影响。

对模型（1）与（2）进行直接估计，可得处置系数估计量为：

$$\hat{\theta}_0 = \frac{\frac{1}{n} \sum_{i=1}^n (D_i - \hat{m}(X_i))(Y_i - \hat{g}(X_i))}{\frac{1}{n} \sum_{i=1}^n D_i (D_i - \hat{m}(X_i))} \quad (4)$$

其中， n 为样本容量。该估计量的关键在于通过机器学习方法控制高维协变量的影响，并借助 Neyman 正交化降低第一阶段预测误差对第二阶段处理效应估计的影响。

进一步考察该估计量的偏误结构：

$$\sqrt{n}(\hat{\theta}_0 - \theta_0) = a + b \quad (5)$$

其中， a 服从均值为零的正态分布。需要特别注意的是， b 项来源于机器学习估计所引入的“正则偏误”。双重机器学习采用机器学习及其正则化算法估计具体函数形式 X_{it} ，虽能有效控制估计量方差过大的问题，但也导致估计量不再具有无偏性。具体而言， X_{it} 向真实函数 $g(X_{it})$ 的收敛速度较慢，即：

$$n^{-\phi_g} > n^{-1/2} \quad (6)$$

这意味着，当样本量 n 趋于无穷大时， b 项亦趋于无穷大，从而 $\hat{\theta}_0$ 难以收敛于真实参数 θ_0 。

为加快收敛速度，本文进一步构建辅助回归方程：

$$Y - \hat{g}(X) = \theta(D - \hat{m}(X)) + \epsilon \quad (7)$$

$$\epsilon = \varepsilon + (g(X) - \hat{g}(X)) + \theta(\hat{m}(X) - m(X)) \quad (8)$$

通过上述辅助回归，结果变量与处理变量中由控制变量解释的部分被剔除，处理效应主要由二者的剩余变动识别。选择 DML 方法主要基于本文研究对象和数据特征。首先，公共数据开放平台上线并非完全随机，可能与城市经济发展水平、数字基础设施、治理能力和政策环境等因素相关，需要控制较多城市层面特征。其次，企业诉求表达受到经济、产业、财政、公共服务和治理水平等多重因素影响，变量之间可能存在复杂的非线性关系，传统线性模型难以充分刻画。最后，DML 能够结合机器学习方法的灵活拟合能力与正交化处理的因果识别优势，在高维控制变量条件下提取公共数据开放的净效应，因而适合用于评估公共数据开放对企业诉求表达活跃度的影响。

五、实证分析

（一）基准回归分析

本文运用双重机器学习模型考察公共数据开放对企业诉求的影响。在模型估计中，样本分割比例设置为 1:4，并采用随机森林（Random Forest）作为核心机器学习算法进行因果识别。选择该算法的主要原因在于：第一，随机森林通过集成多个决策树进行预测，能够有效处理高维控制变量与非线性关系，无需预设函数形式，具备较强的灵活性与稳健性；第二，该算法通过随机抽样与特征子集选择机制，降低了单一决策树的过拟合风险，提升了模型的泛化能力；第三，随机森林能够输出变量的重要性排序，有助于识别影响企业诉求的关键因素，契合本文高维控制变量下因果识别的分析需求。[25][26]

表 5 基准回归结果

模型	post		P 值	控制变量	时间固定效应	样本数
Random Forest	0.2784***	(0.087)	0.001	是	是	4827

注：括号内为标准误；***、**、*分别表示在 1%、5%、10%的水平上显著。

（二）因果识别检验

1. 事件研究法与平行趋势检验




图 2 平行趋势检验

为检验公共数据开放平台上线前处理组与对照组是否具有可比趋势，本文采用事件研究法进行平行趋势检验。以平台上线前一年作为基准期，设置政策实施

前后各期的相对时间虚拟变量，并控制城市固定效应、年份固定效应及城市层面控制变量。若政策实施前各期系数不显著，则说明处理组和对照组在政策前不存在系统性趋势差异。

估计结果显示，政策实施前各期系数整体未通过显著性检验，说明公共数据开放平台上线前，处理组与对照组企业诉求表达活跃度不存在显著差异，平行趋势假设基本成立。政策实施后，第 1 期、第 2 期和第 3 期系数分别为 0.22、0.28 和 0.31，且均显著为正，表明公共数据开放对企业诉求表达活跃度的促进效应具有一定滞后性，并在政策实施后逐步释放。

2. 安慰剂检验

为排除基准结果由随机因素或不可观测冲击驱动的可能性，本文进一步采用随机置换政策时点的安慰剂检验。具体而言，在保持样本结构不变的基础上，为每个城市随机指定伪政策实施年份，重新构造处理变量并估计政策效应，重复 500 次后得到伪处理效应的经验分布。若真实政策效应位于伪效应分布的尾部，则说明基准结果不太可能由随机因素导致。




图 3 安慰剂检验：随机置换政策时点的伪效应分布

检验结果显示，500 次随机模拟得到的伪处理效应主要集中在 0 附近，而真实政策效应明显偏离伪效应分布主体，处于分布尾部。这表明公共数据开放对企业诉求表达活跃度的促进作用并非随机置换政策时点所能解释，进一步增强了本文因果识别结果的可信度。

（三）稳健性检验

1. 调整研究样本

考虑到中国各地区数字基础设施与信息化发展水平存在较大差距，极端样本可能对平均处理效应的估计构成干扰。本文在基准回归所用 282 个地级及以上城市样本的基础上，剔除数字基础设施相对薄弱的甘肃、青海、宁夏、新疆、西藏、云南、贵州七省（区）城市，以及经济发展水平与政策环境较为特殊的北京、天津、上海、重庆四个直辖市，重新进行 DML 估计。结果显示公共数据平台开放的因果效应系数为 0.3636，且在 1%水平上显著。该系数方向与基准结果一致，绝对值略有上升，表明在排除基础条件迥异的样本后，公共数据开放对企业诉求的促进效应依然显著，基准结论未因样本选择而产生根本性改变。^{[25][26]}

2. 剔除异常值影响

样本中的异常观测值可能导致估计结果存在偏误。为此，本文对除处置变量外的所有连续变量与控制变量进行了双侧 1%与 99%分位点的缩尾处理，并将缩尾后的样本重新纳入 DML 模型进行估计。估计结果表明，公共数据平台开放的平均处理效应系数为 0.1705，在 5%水平上统计显著。相较于基准回归系数，缩尾后的效应估计值有所下降，但符号方向保持一致且通过显著性检验，说明在剔除极端值影响后，公共数据开放对企业诉求表达的正向促进作用依然稳健成立。

3. 考虑省份—时间交互固定效应

为排除随省份和年份共同变化的不可观测因素对估计结果的潜在干扰，本文进一步在控制变量组中引入省份与年份的交互固定效应。在控制该更严格固定效应结构后，重新进行 DML 估计。结果显示，公共数据开放的估计系数为 0.2956，仍在 1%水平上显著。该系数大小与基准回归系数 0.2784 高度接近，说明在吸收省级—年度层面的系统性差异后，公共数据开放对企业诉求的正向处理效应保持稳定，核心结论未受遗漏的省-年度异质性因素驱动。

4. 更换机器学习模型

为检验基准结果对模型设定的敏感性，本文在双重机器学习框架下更换第一阶段与第二阶段的机器学习算法。在保持变量设定、样本范围及时间固定效应不变的前提下，分别采用随机森林（Random Forest）、极端梯度提升（XGBoost）、

轻量梯度提升（LightGBM）以及梯度提升决策树（GBDT）作为学习器，对处理变量与结果变量进行拟合，并重新估计公共数据开放的平均处理效应（ATE），结果如表 6 所示。

表 6 更换机器学习模型的结果

变量	RandomForest	XGBoost	LightGBM	GBDT
	(1)	(2)	(3)	(4)
post	0.2784*** (0.087)	0.5887*** (0.107)	0.2248*** (0.171)	1.1241*** (2.951)
P 值	0.001	0.001	0.003	0.000
控制变量	是	是	是	是
时间固定效应	是	是	是	是
样本数	4827	4827	4827	4827

注：括号内为标准误；***、**、*分别表示在 1%、5%、10%的水平上显著。

从估计结果来看，不同模型设定下核心解释变量“公共数据开放”（post）的系数均显著为正，且均通过至少 1%显著性水平检验，表明公共数据开放显著提升企业诉求表达水平。这一结果在不同机器学习算法下保持高度一致，说明本文结论不依赖于特定模型设定，具有较强的稳健性。

5. 更换交叉折数

双重机器学习（DML）的核心优势在于通过正交化与交叉拟合策略，在高维控制变量与复杂函数形式下实现对处理效应的一致估计，为降低样本分割方式对估计结果的潜在影响，并进一步抑制过拟合带来的噪声干扰，本文对 DML 估计中的交叉拟合折数（K）进行敏感性检验。基准回归采用 K=5 的交叉拟合结构，此处分别将交叉折数调整为 K=4 和 K=6，并重新估计公共数据平台开放的平均处理效应。结果显示，当 K=4 时，估计系数为 0.204，在 1%水平上显著；当 K=6 时，估计系数为 0.2256，同样在 1%水平上显著。两种设定下的系数值与基准回归系数（0.2784）方向一致，且在统计显著性上无实质变化。这表明，改变交叉折数未对核心结论造成明显影响，具有较强的稳健性。

6. 替换被解释变量

为检验基准结论是否依赖于企业诉求量的具体度量方式,本文进一步构造替代被解释变量进行稳健性检验。

表 7 替代被解释变量检验结果

被解释变量	ATE	P 值
基准	0.3016***	0.018
ln(万人诉求量+1)	0.2833***	0.024
每万人诉求量	0.2789***	0.019
ln(诉求/GDP)	0.3381***	0.000
ln(诉求/外企)	0.7159***	0.005

注: ***, **、*分别表示在 1%、5%、10%的水平上显著。

回归结果表明,替换被解释变量后,公共数据开放的估计系数仍保持正向且显著,说明无论从人口规模、经济规模还是企业规模角度重新度量企业诉求表达,公共数据开放均能够提升企业诉求表达活跃度,基准结论具有较强稳健性。

(四) 异质性检验

我国地域广阔,区域间在经济发展水平、产业结构、要素禀赋以及制度环境等方面呈现明显分化。为进一步考察公共数据开放对企业诉求量影响的区域差异,本文依据国家统计局区域划分标准,将样本划分为东部、中部、西部及东北四大区域。东部地区包括北京、天津、河北、上海、江苏、浙江、福建、山东、广东和海南 10 省(市);中部地区包括山西、安徽、江西、河南、湖北和湖南 6 省;西部地区包括内蒙古、广西、重庆、四川、贵州、云南、西藏、陕西、甘肃、青海、宁夏和新疆 12 省(区、市);东北地区包括辽宁、吉林和黑龙江。并在各子样本中分别采用随机森林-双重机器学习方法进行估计。结果如表 8 所示。

表 8 异质性分析结果

地区	东部	中部	东北	西部
ATE	0.3534***	1.7834***	2.1592**	1.3602***

注: ***, **、*分别表示在 1%、5%、10%的水平上显著。

从估计结果来看,公共数据开放在各区域均对企业诉求量产生正向影响,但显著性与作用强度存在明显差异,公共数据开放对企业诉求行为的促进作用在东北和中部地区更为显著,而在东部地区则表现出较弱的边际效应。对于这一现象,

可能原因在于：

1. 东北地区：产业结构偏重与信息摩擦较高

东北地区长期以传统工业为主，市场活力相对不足，政企之间信息不对称程度较高。公共数据开放通过提供更加透明的信息环境，有助于降低信息获取成本，推动企业更有效地表达自身诉求，从而在该地区产生较强的促进作用。

2. 中部地区：产业承接与转型带来的需求释放

中部地区正处于承接东部产业转移与经济结构转型阶段，企业数量增长较快，对制度环境与信息资源的依赖程度较高。公共数据开放为企业提供了更多获取政策与市场信息的渠道，有助于优化资源配置，进而促进企业诉求表达行为的提升。

3. 西部地区：基础约束下的吸收能力限制

西部地区在信息基础设施和市场发育程度方面相对滞后，尽管公共数据开放能够提供新的信息资源，但由于数据要素利用能力与制度配套环境尚不完善，其潜在效应难以及时转化为企业行为响应。因此，其促进作用虽显著，但整体弱于中部和东北地区。

4. 东部地区：信息环境完善与边际效应递减

东部地区经济发展水平较高，市场化程度和信息透明度已处于较高水平，企业获取信息与表达诉求的渠道相对丰富。在此背景下，公共数据开放所带来的信息增量有限，因而对企业诉求行为的边际促进作用相对较弱。

六、机制分析

在评估公共数据开放对企业诉求的影响时，不仅要考察其总体的促进效应，更需识别其发挥作用的传导路径。本文认为，公共数据开放通过优化地区营商环境，构成了提升企业诉求表达活跃度的重要传导机制。

（一）公共数据开放对营商环境的驱动逻辑

1. 金融服务环境维度

公共数据开放可整合工商登记、纳税信用、社保缴纳、司法信息等数据，缓解银企信息不对称，提升企业融资政策识别能力和信贷服务可得性。信息透明度提高后，企业更容易发现融资堵点，并通过正式渠道提出融资诉求和政策反馈。

2. 人力要素环境维度

公共数据开放通过提升劳动力市场的匹配效率，优化人力要素配置。开放的就业信息、技能培训资源、人才政策数据，降低了企业与求职者之间的搜寻成本。劳动力数量（年末单位从业人员数）与劳动力质量（普通高等学校在校学生数）的改善，为企业提供了充足且优质的人力资本储备，进而增强企业通过正式渠道表达诉求的积极性。

3. 市场环境维度

公共数据开放通过提高市场透明度，降低企业的制度性交易成本。人均 GDP 与 GDP 增速反映了地区的经济活力与市场规模；进出口总额与外商直接投资额则体现了地区的开放程度。公共数据开放使企业能够更及时地获取市场准入、贸易政策、投资环境等信息，降低企业制度性交易成本，进而增强企业通过正式渠道表达诉求的积极性。

4. 社会服务环境维度

公共数据开放推动水、气、电等公共服务的数字化与智能化转型。供水能力、供气能力、工业供电能力等基础设施数据的开放，便于企业实时监控资源使用情况并优化生产调度；医疗服务数据的开放则有助于企业制定更完善的职工健康保障方案，进而增强企业通过正式渠道表达诉求的积极性。

5. 创新环境维度

公共数据开放能够释放科技项目、专利信息、研发补贴和创新平台等资源，降低企业技术搜索与政策获取成本。创新信息更加透明后，企业能够更精准识别研发支持机会，并围绕技术创新、知识产权和政策扶持表达诉求。

（二）营商环境指标构建

参考王鸿（2026）的研究思路，本文从金融服务环境、人力要素环境、市场环境、社会服务环境与创新环境五个维度，构建城市营商环境评价指标体系。各层级指标的具体构成及权重如表 7 所示，权重通过熵值法测算得出。^{[22][27][28]}

为缓解城市规模差异的影响，本文对部分总量型指标进行了对数化或比率化处理，并在控制变量中纳入经济规模、人口密度等城市规模相关变量。

表 9 营商环境指标构建

一级指标	二级指标	三级指标	指标方向	指标权重
金融服务环境	民间融资效率	年末金融机构各项存款余额（万元）	正项	0.016
	总体融资效率	年末金融机构各项贷款余额（万元）	正项	0.012
	劳动力数量	年末单位从业人员数（万人）	正项	0.155
	劳动力质量	普通高等学校在校学生数（人）	正项	0.135
市场环境	内部指标	人均 GDP（万元）	正项	0.024
		GDP 增速（%）	正项	0.001
	外部指标	进出口总额（万元）	正项	0.010
		外商直接投资额（万元）	正项	0.003
社会服务环境	水力供应	公共供水能力（万吨）	正项	0.192
	天然气供应	公共供气能力（万立方米）	正项	0.214
	电力供应	工业供电能力（万千瓦时）	正项	0.008
	医疗服务	医院床位数（张/万人）	正项	0.007
创新环境	创新投入	地方财政科学费用支出（万元）	正项	0.213

（三）基于 DML 的中介效应检验模型

传统中介效应检验通常采用温忠麟等提出的“三步法”，即依次检验总效应、自变量对中介变量的影响，以及在同时纳入中介变量后的直接效应。然而，江艇（2022）指出，传统“三步法”在因果识别与机制解释层面存在一定局限，尤其是在总效应与中介路径均显著的情况下，继续引入第三步“同时回归”并非必要，还可能因“坏控制”（bad control）问题而导致估计偏误。因此，江艇（2022）主张，在研究重点为“机制存在性”而非精确分解直接效应与间接效应时，只需检验“自变量影响中介变量”与“中介变量影响因变量”两条路径即可判定机制成立。

与此同时，考虑到本文控制变量维度较高，且变量之间可能存在复杂非线性关系，传统线性回归容易产生函数形式误设与高维正则偏误问题。为提高机制识别的稳健性，本文进一步将双重机器学习（Double Machine Learning, DML）引

入中介效应检验框架，通过机器学习方法对高维控制变量进行非参数拟合，并利用交叉拟合（cross-fitting）与正交化（orthogonalization）构建去偏估计量，从而实现更加稳健的因果识别。[26][27][28]

第一步，检验公共数据开放对营商环境的影响：

$$\text{env}_{it} = g_1(W_{it}) + \beta_1 \cdot \text{post}_{it} + \epsilon_{it} \quad (9)$$

其中， post_{it} 表示公共数据开放政策变量， env_{it} 表示营商环境指标， W_{it} 为控制变量集合。 g_1 为机器学习模型对高维控制变量的非参数拟合函数。本文采用随机森林（Random Forest）作为核心学习器，以捕捉控制变量与营商环境之间可能存在的复杂非线性关系。DML 通过交叉拟合构造如下正交矩条件：

$$E[(\text{env}_{it} - g_1(X_{it}) - \beta_1 \text{post}_{it}) \cdot (\text{post}_{it} - E[\text{post}_{it}|X_{it}])] = 0 \quad (10)$$

其中， β_1 表示公共数据开放对营商环境的平均因果效应。若该系数显著，则说明公共数据开放能够有效改善地区营商环境。

第二步，检验营商环境对企业诉求的影响：

$$Y_{it} = g_2(W_{it}, \text{post}_{it}) + \gamma_1 \cdot \text{env}_{it} + \eta_{it} \quad (11)$$

其中， Y_{it} 表示企业诉求， g_2 用于拟合控制变量及政策变量对企业诉求的非线性影响，中介变量 env_{it} 不进入机器学习部分，以保留其结构性解释效应。对应的正交矩条件为：

$$E[(Y_{it} - g_2(X_{it}, \text{post}_{it}) - \gamma_1 \text{env}_{it}) \cdot (\text{env}_{it} - E[\text{env}_{it}|W_{it}, \text{post}_{it}])] = 0 \quad (12)$$

若 γ_1 显著，则说明在控制公共数据开放与其他高维特征后，营商环境仍会显著影响企业诉求。

依据江艇（2022）的机制识别逻辑，当第一步中的 β_1 与第二步中的 γ_1 同时显著时，即可认为营商环境在公共数据开放影响企业诉求过程中发挥了显著中介作用，而无需进一步进行传统“三步法”中的直接效应检验。

从表 10 列（1）可以看出，公共数据开放（post）对企业诉求表达活跃度的系数显著为正，说明数据开放平台上线后，企业通过正式渠道表达诉求的活跃度显著提升。从列（2）看出营商环境对企业诉求表达活跃度的系数同样显著为正，

说明营商环境的改善能够直接促进企业通过正式渠道表达诉求。结合已有理论与文献，公共数据开放通过提升政府透明度、降低信息不对称，能够有效改善地区营商环境，这一关系在既有研究中已得到充分验证。[21][22]由此可以推断，公共数据开放通过优化营商环境这一传导路径，间接促进了企业诉求表达活跃度的提升，即营商环境在其中发挥了显著的中介作用。

表 10 公共数据开放对企业诉求表达及营商环境影响的回归结果

Var	(1)公共数据开放	(2)营商环境指数
系数值	7.644***	0.103***
p	0.00***	0.00***
标准误	0.015	0.006
省份固定效应	控制	控制
年份固定效应	控制	控制
样本量	4658	4658

注：***、**、*分别表示在 1%、5%、10%的水平上显著。

七、研究结论和展望

（一）结论

本文基于我国 2011—2023 年城市层面面板数据，运用双重机器学习方法，系统考察了公共数据开放对企业诉求行为的影响及其机制，并得出以下结论：

第一，公共数据开放对企业诉求产生了显著的正向驱动效应。基准估计结果表明，公共数据平台的开放显著提升了企业通过领导留言板反映诉求的活跃度。这一结论在调整研究样本、剔除异常值观测以及引入省份一时间交互固定效应等一系列稳健性检验后依然成立，表明公共数据平台的开放稳健地降低了企业与政府沟通的信息门槛，提升了企业通过反映诉求的积极性。

第二，公共数据开放对企业诉求的影响存在显著的区域异质性。从区域分组估计结果看，东北地区与中部地区的企业诉求表达行为对公共数据开放政策的响应最为显著，西部地区次之，东部地区的边际效应则相对有限。这一差异格局反映出不同区域在初始营商环境基础、数字化设施完备程度以及替代性诉求渠道可得性等方面的分化，在制度环境改善空间较大的地区，公共数据开放带来的信息红利更为突出。

第三，公共数据开放通过优化地区营商环境，进一步提升企业诉求表达活跃

度。本文基于金融服务、人力要素、市场环境、社会服务与创新环境五个维度构建营商环境指标，并开展机制检验。结果表明，公共数据开放能够通过改善营商环境，降低企业获取政策、融资、用工、审批和创新资源等信息的成本，增强企业对正式政企沟通渠道的信任和使用意愿，从而进一步促进企业通过领导留言板等公开平台表达经营诉求和政策建议。

（二）建议

对应上述结论，本文提出三点政策建议。

其一，持续深化公共数据开放平台建设，强化政企沟通的制度化保障。鉴于公共数据开放能够显著提升企业诉求表达水平，应将其作为优化营商环境的基础性制度安排，在拓展数据覆盖广度与更新频次的同时，配套提升政府对诉求的分流、回应与办理能力，实现企业表达意愿与政府回应效能的动态均衡。

其二，依据区域差异制定梯度化的数据开放策略。对于东北和中部等公共数据开放边际效应较强的地区，应在扩大数据开放的同时着力加强基层诉求响应体系建设，确保企业诉求从表达环节顺畅过渡至解决环节；对于东部等效应已趋于平稳的地区，则应侧重数据开放的纵深发展与智能化应用，探索基于企业画像的精准政策服务，释放数据要素的赋能潜力。

其三，以营商环境关键领域为重点推进数据精准开放，提升企业诉求表达质量和政企沟通效率。机制分析表明，营商环境改善是公共数据开放提升企业诉求表达活跃度的重要通道。因此，应优先推进企业信用、用工监测、审批进度、知识产权、公共服务保障等与企业经营密切相关的数据开放，降低企业信息搜寻成本和制度性交易成本，增强企业对正式沟通渠道的信任，使企业诉求能够更及时、更准确地被识别、回应和解决。

八、参考文献

- [1]. 郑石明.数据开放、公众参与和环境治理创新[J].行政论坛,2017,24(04):76-81.DOI:10.16637/j.cnki.23-1360/d.2017.04.012.
- [2]. 蔡菲莹,黄秀霁.政府数据开放、企业数字化转型与企业创新[J].统计与决策,2022,38(23):175-179.DOI:10.13546/j.cnki.tjyjc.2022.23.033.
- [3]. 黄先海,虞柳明.政府数据开放能提升城市创新水平吗——来自中国地级市的证据[J].浙江学刊,2023,(04):88-98.DOI:10.16235/j.cnki.33-1005/c.2023.04.005.
- [4]. 章昌平,常继元,陈玲玲,等.数据开放对区域创新能力的作用机制分析——基于政务服务便捷性的中介作用[J].科技管理研究,2024,44(01):51-60.
- [5]. 张莉,林安然.中国地方政府数据开放与经济发展质量[J].公共行政评论,2023,16(02):120-137+198-199.
- [6]. 赵丽丽,郝文强.政府数据开放对数字经济的影响[J].统计与决策,2023,39(18):67-72.DOI:10.13546/j.cnki.tjyjc.2023.18.012.
- [7]. 彭远怀.政府数据开放的价值创造作用:企业全要素生产率视角[J].数量经济技术经济研究,2023,40(09):50-70.DOI:10.13653/j.cnki.jqte.20230725.001.
- [8]. 杨秀云,韩奇.公共数据开放能提升企业全要素生产率吗?[J].证券市场导报,2023,(12):18-30.
- [9]. 吴武清,李祁恒,章柳漪,等.公共数据资源与企业全要素生产率——基于地方政府数据开放的准自然实验[J].系统工程理论与实践,2024,44(06):1815-1833.
- [10]. 蔡运坤,周京奎,袁旺平.数据要素共享与城市创业活力——来自公共数据开放的经验证据[J].数量经济技术经济研究,2024,41(08):5-25.DOI:10.13653/j.cnki.jqte.20240619.004.
- [11]. 罗党论,刘晓龙.政治关系、进入壁垒与企业绩效——来自中国民营上市公司的经验证据[J].管理世界,2009,(05):97-106.DOI:10.19744/j.cnki.11-1235/f.2009.05.012.
- [12]. 宋林霖,何成祥.优化营商环境视阈下“放管服”改革的逻辑与推进路径——基于世界银行营商环境指标体系的分析[J].今日海南,2018,(08):29-33+36.
- [13]. 余明桂,潘红波.政治关系、制度环境与民营企业银行贷款[J].管理世界,2008,(0

- 8):9-21+39+187.DOI:10.19744/j.cnki.11-1235/f.2008.08.002.
- [14]. 潘士远,陈秀茂,任晓猛,等.优化减税降费结构:提振民营经济发展的重要路径[J].经济学家,2023,(07):97-107.DOI:10.16158/j.cnki.51-1312/f.2023.07.012.
- [15]. 卢圣华,汪晖.中国式现代化进程中的民营企业诉求:基于“地方领导留言板”和大语言模型的实证分析[J].浙江大学学报(人文社会科学版),2024,54(09):84-97.
- [16]. 赵涛,张智,梁上坤.数字经济、创业活跃度与高质量发展——来自中国城市的经验证据[J].管理世界,2020,36(10):65-76.DOI:10.19744/j.cnki.11-1235/f.2020.0154.
- [17]. 张涛,李均超.网络基础设施、包容性绿色增长与地区差距——基于双重机器学习的因果推断[J].数量经济技术经济研究,2023,40(04):113-135.DOI:10.13653/j.cnki.jqte.20230310.005.
- [18]. 田坤,黄坤,行伟波.数字经济、市场潜能与乡村振兴——基于双重机器学习的因果推断[J].山西财经大学学报,2023,45(11):73-85.DOI:10.13781/j.cnki.1007-9556.2023.11.006.
- [19]. 赵燕,孙慧,马点圆.城市绿色金融改革对减污降碳协同增效的影响研究——基于双重机器学习的因果推断[J].产业经济研究,2024,(03):15-28+58.DOI:10.13269/j.cnki.ier.2024.03.008.
- [20]. 李成友,孙涛,王硕.人口结构红利、财政支出偏向与中国城乡收入差距[J].经济学动态,2021,(01):105-124.
- [21]. 方锦程,刘颖,高昊宇,等.公共数据开放能否促进区域协调发展?——来自政府数据平台上线的准自然实验[J].管理世界,2023,39(09):124-142.DOI:10.19744/j.cnki.11-1235/f.2023.0112.
- [22]. 王鸿,邱春华.营商环境优化何以赋能战略性新兴产业绿色创新——基于双重机器学习的因果推断[J].调研世界,2026,(04):52-65.DOI:10.13778/j.cnki.11-3705/c.2026.04.005.
- [23]. 牛朝文,赵怀宇.数字基础设施建设能否优化城市营商环境?——来自“宽带中国”试点政策的经验证据[J/OL].经济与管理,1-13[2026-05-04].<https://link.cnki.net/urlid/13.1032.F.20260401.1840.008>.
- [24]. 蔡运坤,周京奎,袁旺平.数据要素共享与城市创业活力——来自公共数据开

- 放的经验证据[J].数量经济技术经济研究,2024,41(08):5-25.DOI:10.13653/j.cnki.jqt
e.20240619.004.
- [25]. 刘明,宋彦玲. 经济学实证研究中的稳健性检验方法——基于检验逻辑视角
的阐释[J].统计与决策,2023,39(12):45-50.DOI:10.13546/j.cnki.tjyj.2023.12.008.
- [26]. 温忠麟,方杰,谢晋艳,等. 国内中介效应的方法学研究[J].心理科学进展,2022,3
0(08):1692-1702.
- [27]. 江艇. 因果推断经验研究中的中介效应与调节效应[J].中国工业经济,2022,(0
5):100-120.DOI:10.19581/j.cnki.ciejournal.2022.05.005.
- [28]. 温忠麟,叶宝娟. 中介效应分析:方法和模型发展[J].心理科学进展,2014,22(05):
731-745.
- [29]. Song, L., Jing, J., Yan, Z. et al. Does government information transparency
contribute to pollution abatement? Evidence from 264 Chinese cities. *Environ S
ci Pollut Res* 29, 12853–12863 (2022).
- [30]. Fusi, Federica ; Zhang, Fengxiu ; Liang, Jiaqi. / Unveiling environmental ju
stice through open government data : Work in progress for most US states. I
n: *Public Administration*. 2023 ; Vol. 101, No. 3. pp. 1088-1114.
- [31]. Liu, Z., Yu, Y. & Lei, Y. Enhancing local governments' environmental atte
ntion through open government data: evidence from China. *Environ Sci Pollut
Res* 31, 18494–18511 (2024).
- [32]. Yan, R., et al., Is it real or illusory? An empirical examination of the imp
act of open government data on innovation capability in the case of China. *Te
chnology in Society*, 2023. 75: p. 102396.
- [33]. Wang R, Xu C K, Wu X. Open Government Data (OGD) as a catalyst for
smart city development: Empirical evidence from Chinese cities[J]. *Governmen
t Information Quarterly*, 2024,41(4):101983.
- [34]. Pfeffer, J., & Salancik, G. R. (1978). *The External Control of Organizations:
A Resource Dependence Perspective*. Harper & Row.
- [35]. North, D.C. (1990). *Institutions, institutional change and economic performan*

- ce. Cambridge University Press.
- [36]. Modigliani, F., & Miller, M.H. (1958). The cost of capital, corporation finance and the theory of investment. *American Economic Review*, 48(3), 261-297.
 - [37]. Dawes S S. Stewardship and usefulness: Policy principles for information-based transparency[J]. *Government Information Quarterly*, 2010,27(4):377-383.
 - [38]. Janssen M, Charalabidis Y, Zuiderwijk A. Benefits, Adoption Barriers and Myths of Open Data and Open Government[J]. *Information Systems Management*, 2012,29(4):258-268.
 - [39]. Gu J, Jiang X, Shi Z, et al. A survey on llm-as-a-judge[J]. *The Innovation*, 2024.
 - [40]. Ye J, Wang Y, Huang Y, et al. Justice or prejudice quantifying biases in llm-as-a-judge[C]International Conference on Learning Representations. 2025, 2025 102351-102390.
 - [41]. Chen D, Chen R, Zhang S, et al. Mllm-as-a-judge: Assessing multimodal llm-as-a-judge with vision-language benchmark[C]//Forty-first International Conference on Machine Learning. 2024.

九、附录

DML 核心代码:

```
1 import pandas as pd
2 import numpy as np
3 from econml.dml import LinearDML
4 from sklearn.linear_model import LassoCV, LogisticRegressionCV, RidgeCV
5 from sklearn.ensemble import RandomForestRegressor, RandomForestClassifier, GradientBoostingRegressor, \
6     GradientBoostingClassifier
7 from xgboost import XGBRegressor, XGBClassifier
8 from lightgbm import LGBMRegressor, LGBMClassifier
9 from sklearn.preprocessing import StandardScaler
10 from tabulate import tabulate
11 import warnings
12
13 warnings.filterwarnings('ignore')
14
15 # 1. 基础设置与数据读取
16 file_path = r"D:\Desktop\我的竞赛\2026统计建模\2_处理后含控制变量数据.xlsx"
17 print("正在读取数据...")
18 df = pd.read_excel(file_path)
19
20 # 2. 变量预处理
21 # A. 对诉求量取对数  $\log(Y + 1)$ 
22 y_col = '诉求量_log'
23 df[y_col] = np.log1p(df['诉求量'])
24
25 # B. 处理时间固定效应 (年份在第E列, 即索引4)
26 year_col_name = df.columns[4]
27 print(f"检测到年份列: {year_col_name}")
28 year_dummies = pd.get_dummies(df[year_col_name], prefix='year', drop_first=True)
29 year_dummy_cols = year_dummies.columns.tolist()
30
31 # C. 处理地区变量 (地区在第A列/ 省份)
32 region_col_name = df.columns[0]
33 print(f"检测到地区列: {region_col_name}")
34
35 # D. 确定控制变量 (X)
36 t_col = 'post (开放数据平台时间虚拟变量)'
37 controls = ['地区生产总值(万元)', '人口密度(人/平方公里)', '第三产业增加值占GDP比重(%)', '人力资本水平', '每百人公共图书馆藏书(册、件)',
38             '传统基础设施', '互联网发展水平', '金融发展水平', '财政压力水平', '科学支出水平', '城市发展水平', '外商投资水平', '生活垃圾无害化处理']
39 # 最终控制变量 = 自定义变量 + 时间固定效应虚拟变量 (保留原有的时间效应)
40 x_cols = controls + year_dummy_cols
41
42 # 整合数据并删除缺失值
43 df_final = pd.concat([df, year_dummies], axis=1)
44 cols_to_use = [y_col, t_col, region_col_name] + x_cols
45 df_dml = df_final.dropna(subset=cols_to_use).copy()
46
47 # 3. 定义全套机器学习模型组合
48 # 注意: 对于 Ridge 分类器, 我们使用 LogisticRegressionCV(penalty='l2') 作为等效实现
49 models_dict = {
50     "1. Lasso (L1正则化)": (
51         LassoCV(cv=5),
52         LogisticRegressionCV(cv=5, penalty='l1', solver='saga', max_iter=1000)
53     ),
54     "2. Ridge (L2正则化)": (
55         RidgeCV(cv=5),
56         LogisticRegressionCV(cv=5, penalty='l2', solver='lbfgs', max_iter=1000)
57     ),
58     "3. RandomForest (随机森林)": (
59         RandomForestRegressor(n_estimators=50, max_depth=6, n_jobs=-1, random_state=123),
60         RandomForestClassifier(n_estimators=50, max_depth=6, n_jobs=-1, random_state=123)
61     ),
62 }
```

```

62     "4. GradientBoosting (GBDT)": (
63         GradientBoostingRegressor(n_estimators=100, learning_rate=0.1, max_depth=4, random_state=123),
64         GradientBoostingClassifier(n_estimators=100, learning_rate=0.1, max_depth=4, random_state=123)
65     ),
66     "5. XGBoost (极端梯度提升)": (
67         XGBRegressor(n_estimators=50, max_depth=4, n_jobs=-1, random_state=123),
68         XGBClassifier(n_estimators=50, max_depth=4, n_jobs=-1, random_state=123, use_label_encoder=False,
69                     eval_metric='logloss')
70     ),
71     "6. LightGBM (轻量梯度提升)": (
72         LGBMRegressor(n_estimators=100, max_depth=4, n_jobs=-1, random_state=123, verbose=-1),
73         LGBMClassifier(n_estimators=100, max_depth=4, n_jobs=-1, random_state=123, verbose=-1)
74     )
75 }
76
77 # =====
78 # 第一阶段: 全样本基准回归 (不分地区)
79 # =====
80 print("\n" + "=" * 80)
81 print("第一阶段: 全样本多模型 DML 估计 (控制了时间固定效应)")
82 print("=" * 80)
83
84 Y_all = df_dml[y_col].values
85 T_all = df_dml[t_col].values
86 X_all = df_dml[x_cols].values
87
88 scaler_all = StandardScaler()
89 X_all_scaled = scaler_all.fit_transform(X_all)
90
91 global_results = []
92
93 for model_name, (mod_y, mod_t) in models_dict.items():
94     print(f"正在运行全样本模型: {model_name} ...")
95     try:
96         est = LinearDML(model_y=mod_y, model_t=mod_t, discrete_treatment=True, cv=5, random_state=456)
97         est.fit(Y_all, T_all, X=X_all_scaled, W=None)
98
99         ate = est.const_marginal_ate(X_all_scaled).item()
100         summary_table = est.summary().tables[1]
101         p_val = float(summary_table.data[1][4])
102         stderr = float(summary_table.data[1][2])
103
104         # 标记显著性星号
105         stars = "***" if p_val < 0.01 else "*" if p_val < 0.05 else "" if p_val < 0.1 else ""
106         global_results.append([model_name, f"{ate:.4f}{stars}", f"{stderr:.4f}", f"{p_val:.4f}"])
107     except Exception as e:
108         print(f" [!] {model_name} 运行失败: {e}")
109         global_results.append([model_name, "Error", "Error", "Error"])
110
111 print("\n【全样本基准结果汇总】")
112 print(tabulate(global_results, headers=["模型组合", "ATE (log效应)", "标准误", "P值"], tablefmt="grid"))
113

```